

LDA和QDA的分类原理

0. 参考资料

CSDN 判别模型: [logistic,GDA,QDA \(一\)](#)

<https://esl.hohoweiya.xyz/04-Linear-Methods-for-Classification/4.3-Linear-Discriminant-Analysis/index.html>

scikit-learn官网 https://scikit-learn.org/stable/modules/lda_qda.html#mathematical-formulation-of-the-lda-and-qda-classifiers

吴恩达CS229讲义中相关内容

《ESL》一书中对应章节

1. LDA

线性判别分析 (Linear Discriminant Analysis, LDA) 和二次判别分析 (Quadratic Discriminant Analysis, QDA) 都是分类的生成模型, 它们的原理与贝叶斯法则有关。

对于分类问题而言, 我们需要求得后验概率 $P(y = k|X)$, 其中 $k = 1, \dots, K$ 代表类别。利用贝叶斯公式可以求得后验概率, 即:

$$P(y = k|X) = \frac{P(X|y = k)P(y = k)}{P(X)} = \frac{P(X|y = k)P(y = k)}{\sum_{l=1}^K P(X|y = l)P(y = l)}$$

对于LDA和QDA, 我们假设 $P(X|y = k)$ 服从多元高斯分布, 先验概率 $P(y = k) = \pi_k$, 这时又称为高斯判别分析 (GDA)。

此时有:

$$\begin{aligned} P(X|y = k) &= f_k(x) \\ &= \frac{1}{(2\pi)^{n/2} |\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}(X - \mu_k)^T \Sigma_k^{-1} (X - \mu_k)\right) \end{aligned}$$

其中 n 为特征维度。

假设所有类别都具有相同的协方差矩阵 $\Sigma_k = \Sigma$, 会导出LDA。在比较两个类别 k 和 l 时, 考虑它们的对数比率即可, 所以有

$$\begin{aligned} &\log \frac{\Pr(y = k|X = x)}{\Pr(y = l|X = x)} \\ &= \log \frac{f_k(x)}{f_l(x)} + \log \frac{\pi_k}{\pi_l} \\ &= \log \frac{\pi_k}{\pi_l} - \frac{1}{2}(\mu_k + \mu_l)^T \Sigma^{-1} (\mu_k - \mu_l) + x^T \Sigma^{-1} (\mu_k - \mu_l) \end{aligned} \tag{1.1}$$

这是个关于 x 的线性等式，协方差矩阵相等消除了二次项，这也是名称“线性判别分析”的由来。

根据式 (1.1) 可以看出线性判别函数为：

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

然后类别 $k^* = \operatorname{argmax}_k \delta_k(x)$ ，这是判别规则的等价描述。

我们可以通过最大后验的方式从数据集中估计参数：

- $\hat{\pi}_k = N_k / N$ ，其中 N_k 是第 k 类观测值的个数；
- $\hat{\mu}_k = \sum_{i:y_i=k} x_i / N_k$ ；
- $\hat{\Sigma} = \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T / (N - K)$ 。

2. QDA

如果我们假设每一类别的协方差矩阵不同，那么式 (1.1) 中方便的抵消就不会发生，这时就是QDA的情况。

此时判别函数变为：

$$\begin{aligned} \delta_k(x) &= -\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log \pi_k \\ &= -\frac{1}{2} x^T \Sigma_k^{-1} x + x^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \log |\Sigma_k| + \log \pi_k \end{aligned}$$

这时 $\delta_k(x)$ 是关于 x 的二次函数。每个类别对 k 和 l 的判别边界由二次等式 $\{x : \delta_k(x) = \delta_l(x)\}$ 来描述。

3. 与LR的联系

可以证明，LDA的后验概率能被表示成logistic回归的形式。那么应该如何选择LDA和LR呢？

注意到LDA假设数据服从多元高斯分布，而某些不服从高斯分布的数据也可以导出LR的形式。因此，LDA的假设要比LR更强。

当数据确实服从多元高斯分布时，使用LDA会带来更好的效果，并且对数据的利用率更高（即只需要少量数据就能学习的很好）。但当数据不服从高斯分布时，强行使用LDA效果不佳，这是LR的表现会更鲁棒，因此实际操作时，我们常常更偏向于使用LR。