

MDS降维原理

【参考资料】

周志华 《机器学习》

MDS全称为多维缩放 (Multiple Dimensional Scaling) , 是一种经典的线性降维技术。其基本思想是**使原始空间中样本点之间的距离在低维空间中得以保持**。

假设 m 个 d 维的样本在原始空间的距离矩阵为 $\mathbf{D} \in \mathbb{R}^{m \times m}$, 其第 i 行第 j 列的元素 $dist_{ij}$ 为样本 x_i 到样本 x_j 的距离。经过降维后, 样本在 d' 维空间的表示 $\mathbf{Z} \in \mathbb{R}^{d' \times m}$, 并且 $d' \leq d$ 。根据MDS的思想, 任意两个样本在 d' 维空间的欧式距离要等于原始空间中的距离, 即 $\|z_i - z_j\| = dist_{ij}$ 。

令 $\mathbf{B} = \mathbf{Z}^T \mathbf{Z} \in \mathbb{R}^{m \times m}$, 其中 \mathbf{B} 为降维后样本的内积矩阵, $b_{ij} = z_i^T z_j$, 有

$$\begin{aligned} dist_{ij}^2 &= \|z_i\|^2 + \|z_j\|^2 - 2z_i^T z_j \\ &= b_{ii} + b_{jj} - 2b_{ij} \end{aligned}$$

为便于讨论, 令降维后的样本 \mathbf{Z} 被中心化, 即 $\sum_{i=1}^m z_i = 0$ 。显然, 矩阵 \mathbf{B} 的行与列之和均为零, 即 $\sum_{i=1}^m b_{ij} = \sum_{j=1}^m b_{ij} = 0$ 。易知

$$\begin{aligned} \sum_{i=1}^m dist_{ij}^2 &= \text{tr}(\mathbf{B}) + mb_{jj} \\ \sum_{j=1}^m dist_{ij}^2 &= \text{tr}(\mathbf{B}) + mb_{ii} \\ \sum_{i=1}^m \sum_{j=1}^m dist_{ij}^2 &= 2m \text{tr}(\mathbf{B}) \end{aligned}$$

其中 $\text{tr}(\mathbf{B}) = \sum_{i=1}^m \|z_i\|^2$ 。令

$$\begin{aligned} dist_{i.}^2 &= \frac{1}{m} \sum_{j=1}^m dist_{ij}^2 \\ dist_{.j}^2 &= \frac{1}{m} \sum_{i=1}^m dist_{ij}^2 \\ dist_{..}^2 &= \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m dist_{ij}^2 \end{aligned}$$

可得

$$b_{ij} = -\frac{1}{2} \left(dist_{ij}^2 - dist_{i.}^2 - dist_{.j}^2 + dist_{..}^2 \right)$$

由此, 即可通过降维前后保持不变的距离矩阵 \mathbf{D} 求取内积矩阵 \mathbf{B} 。

对矩阵 \mathbf{B} 做特征值分解, $\mathbf{B} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T$, 其中 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$ 为特征值构成的对角矩阵, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$, \mathbf{V} 为特征向量矩阵。假定其中有 d^* 个非零特征值, 它们构成对角矩阵 $\mathbf{\Lambda}_* = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d^*})$, 令 \mathbf{V}_* 表示相应的特征向量矩阵, 则 \mathbf{Z} 可表达为

$$\mathbf{Z} = \mathbf{\Lambda}_*^{1/2} \mathbf{V}_*^T \in \mathbb{R}^{d^* \times m}$$

在现实应用中为了有效降维，往往仅需降维后的距离与原始空间中的距离尽可能接近，而不必严格相等。此时，可取 $d' \ll d$ 个最大特征值构成对角矩阵 $\tilde{\mathbf{\Lambda}} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d'})$ ，令 $\tilde{\mathbf{V}}$ 表示相应的特征向量矩阵，则 \mathbf{Z} 可表达为

$$\mathbf{Z} = \tilde{\mathbf{\Lambda}}^{1/2} \tilde{\mathbf{V}}^T \in \mathbb{R}^{d' \times m}$$

MDS算法的完整描述如下：

输入： 距离矩阵 $\mathbf{D} \in \mathbb{R}^{m \times m}$ ，其元素 $dist_{ij}$ 为样本 \mathbf{x}_i 到 \mathbf{x}_j 的距离；
低维空间维数 d' 。

过程：

- 1: 根据式(10.7)~(10.9)计算 $dist_{i.}^2, dist_{.j}^2, dist_{..}^2$;
- 2: 根据式(10.10)计算矩阵 \mathbf{B} ;
- 3: 对矩阵 \mathbf{B} 做特征值分解;
- 4: 取 $\tilde{\mathbf{\Lambda}}$ 为 d' 个最大特征值所构成的对角矩阵, $\tilde{\mathbf{V}}$ 为相应的特征向量矩阵.

输出： 矩阵 $\tilde{\mathbf{V}}\tilde{\mathbf{\Lambda}}^{1/2} \in \mathbb{R}^{m \times d'}$ ，每行是一个样本的低维坐标

MDS和PCA非常相似，都是要计算数据样本点在某个空间中的表示，差别仅在于PCA的输入是样本点在原空间的坐标，而MDS则需要输入各个点的距离度量，事实上已经有证明如果MDS输入的是样本点在原空间的欧式距离，则与PCA等价。