

核PCA原理解析

【参考资料】

[核主成分分析 \(Kernel-PCA\)](#)


[Kernel PCA](#)

[Kernel Principal Component Analysis](#)


周志华 《机器学习》

1. PCA的缺陷


有些高维空间不适合PCA的线性降维方法，这时候就需要一些非线性降维的手段。



(a) 三维空间中的观察



(b) 本真二维结构



(c) PCA 降维结果

2. KPCA原理推导

Kernel PCA的基本思想是将原数据点非线性映射到高维空间，然后在高维空间中进行降维操作。

已知数据集为 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_M$ ，其中 $\mathbf{x}_i \in R^N$ ， $i = 1, 2, \dots, M$ 。存在一个非线性映射 $\Phi: R^N \mapsto R^F$ ，映射后的数据集为 $\Phi(\mathbf{x}_1), \Phi(\mathbf{x}_2), \dots, \Phi(\mathbf{x}_n)$ 。PCA是在 R^N 中讨论的，那么KPCA就是在映射后的空间 R^F 中讨论的。一般情况下，映射 Φ 是无法显式求解的，所以需要引入核函数 $K: R^N \times R^N \mapsto R$ ，使得：

$$K(\mathbf{x}_i, \mathbf{x}_j) = \Phi(\mathbf{x}_i)^T \Phi(\mathbf{x}_j)$$

传统PCA中，我们要求解协方差矩阵及其特征值和特征向量，在KPCA中，我们需要求解的则是映射后的数据的协方差矩阵及其特征向量：

$$C = \frac{1}{M} \sum_{i=1}^M \left(\Phi(\mathbf{x}_i) - \frac{1}{M} \sum_{j=1}^M \Phi(\mathbf{x}_j) \right) \left(\Phi(\mathbf{x}_i) - \frac{1}{M} \sum_{j=1}^M \Phi(\mathbf{x}_j) \right)^T$$

为了讨论方便，令

$$\Psi(\mathbf{x}_i) = \Phi(\mathbf{x}_i) - \frac{1}{M} \sum_{j=1}^M \Phi(\mathbf{x}_j)$$

所以 C 可以表示为

$$C = \frac{1}{M} \sum_{i=1}^M \Psi(\mathbf{x}_i) \Psi(\mathbf{x}_i)^T$$

由于通常映射 Φ 是无法显式求解的，所以我们要从另一个角度来讨论 C 的特征向量的求解。设 \mathbf{v} 是 C 的特征向量， λ 是对应 \mathbf{v} 的特征值，即

$$C\mathbf{v} = \lambda\mathbf{v}$$

$$\frac{1}{M} \sum_{i=1}^M \Psi(\mathbf{x}_i) \Psi(\mathbf{x}_i)^T \mathbf{v} = \lambda\mathbf{v}$$

显然

$$\mathbf{v} = \frac{1}{M\lambda} \sum_{i=1}^M \left(\Psi(\mathbf{x}_i)^T \mathbf{v} \right) \Psi(\mathbf{x}_i)$$

令 $a_i = \frac{1}{M\lambda} \left(\Psi(\mathbf{x}_i)^T \mathbf{v} \right)$, $i = 1, 2, \dots, M$, 使得

$$\mathbf{v} = \sum_{i=1}^M a_i \Psi(\mathbf{x}_i)$$

于是我们便可以知道 C 的特征向量的性质，即 \mathbf{v} 是由 $\Psi(\mathbf{x}_1), \Psi(\mathbf{x}_2), \dots, \Psi(\mathbf{x}_M)$ 张成的。

因为

$$C\mathbf{v} = \lambda\mathbf{v}$$

所以

$$\Psi(\mathbf{x}_k)^T (C\mathbf{v}) = \lambda \Psi(\mathbf{x}_k)^T \mathbf{v}, k = 1, 2, \dots, M$$

把 $\mathbf{v} = \sum_{i=1}^M a_i \Psi(\mathbf{x}_i)$, 带入上式得：

右式：

$$\lambda \Psi(\mathbf{x}_k)^T \mathbf{v} = \lambda \sum_{i=1}^M a_i \Psi(\mathbf{x}_k)^T \Psi(\mathbf{x}_i) = \lambda \begin{bmatrix} \Psi(\mathbf{x}_k)^T \Psi(\mathbf{x}_1) & \Psi(\mathbf{x}_k)^T \Psi(\mathbf{x}_2) & \dots & \Psi(\mathbf{x}_k)^T \Psi(\mathbf{x}_M) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_M \end{bmatrix}$$

左式：

$$\begin{aligned}\Psi(\mathbf{x}_k)^T(C\mathbf{v}) &= \frac{1}{M} \sum_{i=1}^M \left(\Psi(\mathbf{x}_k)^T \left(\sum_{j=1}^M \Psi(\mathbf{x}_j) \Psi(\mathbf{x}_j)^T \right) \Psi(\mathbf{x}_i) \right) \\ &= \frac{1}{M} \begin{bmatrix} \Psi(\mathbf{x}_k)^T \left(\sum_{j=1}^M \Psi(\mathbf{x}_j) \Psi(\mathbf{x}_j)^T \right) \Psi(\mathbf{x}_1) & \cdots & \Psi(\mathbf{x}_k)^T \left(\sum_{j=1}^M \Psi(\mathbf{x}_j) \Psi(\mathbf{x}_j)^T \right) \Psi(\mathbf{x}_M) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_M \end{bmatrix}\end{aligned}$$

其中 $k = 1, 2, 3, \dots, M$ 。

我们用矩阵表示上式等式，即：

$$\lambda \overline{\mathbf{K}} \mathbf{a} = \frac{1}{M} \overline{\mathbf{K}}^2 \mathbf{a}$$

其中：

$$\overline{\mathbf{K}} = \begin{bmatrix} \Psi(\mathbf{x}_1)^T \Psi(\mathbf{x}_1) & \Psi(\mathbf{x}_1)^T \Psi(\mathbf{x}_2) & \cdots & \Psi(\mathbf{x}_1)^T \Psi(\mathbf{x}_M) \\ \Psi(\mathbf{x}_2)^T \Psi(\mathbf{x}_1) & \Psi(\mathbf{x}_2)^T \Psi(\mathbf{x}_2) & \cdots & \Psi(\mathbf{x}_2)^T \Psi(\mathbf{x}_M) \\ \vdots & \vdots & \vdots & \vdots \\ \Psi(\mathbf{x}_M)^T \Psi(\mathbf{x}_1) & \Psi(\mathbf{x}_M)^T \Psi(\mathbf{x}_2) & \cdots & \Psi(\mathbf{x}_M)^T \Psi(\mathbf{x}_M) \end{bmatrix}$$

$$\overline{\mathbf{K}}_{ij} = \Psi(\mathbf{x}_i)^T \Psi(\mathbf{x}_j)$$

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_M \end{bmatrix}$$

那么

$$\lambda M \mathbf{a} = \overline{\lambda} \mathbf{a} = \overline{\mathbf{K}} \mathbf{a}$$

即 \mathbf{a} 是 $\overline{\mathbf{K}}$ 的特征向量。

关于 $\overline{\mathbf{K}}$ 的求法：

设 $\mathbf{I} \in R^{M \times M}$ ， $\mathbf{I}_{ij} = 1$ ， $i = 1, 2, 3, \dots, M$ ， $j = 1, 2, 3, \dots, M$ ，即 \mathbf{I} 为全1矩阵，那么

$$\begin{aligned}\overline{\mathbf{K}}_{ij} &= \Psi(\mathbf{x}_i)^T \Psi(\mathbf{x}_j) = \left(\Phi(\mathbf{x}_i) - \frac{1}{M} \sum_{m=1}^M \Phi(\mathbf{x}_m) \right)^T \left(\Phi(\mathbf{x}_j) - \frac{1}{M} \sum_{n=1}^M \Phi(\mathbf{x}_n) \right) \\ &= \Phi(\mathbf{x}_i)^T \Phi(\mathbf{x}_j) - \frac{1}{M} \sum_{m=1}^M \Phi(\mathbf{x}_m)^T \Phi(\mathbf{x}_j) - \frac{1}{M} \sum_{n=1}^M \Phi(\mathbf{x}_i)^T \Phi(\mathbf{x}_n) + \frac{1}{M^2} \sum_{m,n=1}^M \Phi(\mathbf{x}_m)^T \Phi(\mathbf{x}_n) \\ &= \mathbf{K}_{ij} - \frac{1}{M} \sum_{m=1}^M \mathbf{I}_{im} \mathbf{K}_{mj} - \frac{1}{M} \sum_{n=1}^M \mathbf{K}_{in} \mathbf{I}_{nj} + \frac{1}{M^2} \sum_{m,n=1}^M \mathbf{I}_{im} \mathbf{K}_{mn} \mathbf{I}_{nj}\end{aligned}$$

其中： $\mathbf{K}_{ij} = \Phi(\mathbf{x}_i)^T \Phi(\mathbf{x}_j)$ ， \mathbf{K} 为核矩阵，即 $\mathbf{K}_{ij} = K(\mathbf{x}_i, \mathbf{x}_j) = \Phi(\mathbf{x}_i)^T \Phi(\mathbf{x}_j)$ 。

利用矩阵乘法，可以转化为

$$\bar{\mathbf{K}} = \mathbf{K} - \mathbf{I}_M \mathbf{K} - \mathbf{K} \mathbf{I}_M - \mathbf{I}_M \mathbf{K} \mathbf{I}_M \quad (1)$$

其中 $\mathbf{I}_M = \frac{1}{M} \mathbf{I}$ 。

至此， $\bar{\mathbf{K}}$ 已经求出，那么特征向量 \mathbf{a} 也可以求出了。

求解新数据 \mathbf{t}_j ， $j = 1, 2, 3, \dots, L$ 的核主成分，即求：

$$(\Psi(\mathbf{t}_j), \mathbf{v}) = \sum_{i=1}^M a_i (\Psi(\mathbf{x}_i), \Psi(\mathbf{t}_j)) = \sum_{i=1}^M a_i \Psi(\mathbf{x}_i)^T \Psi(\mathbf{t}_j)$$

同 $\bar{\mathbf{K}}$ 的求法

$$\begin{aligned} \bar{\mathbf{K}}_{ij}^{\text{test}} &= \Psi(\mathbf{x}_i)^T \Psi(\mathbf{t}_j) = \left(\Phi(\mathbf{x}_i) - \frac{1}{M} \sum_{m=1}^M \Phi(\mathbf{x}_m) \right)^T \left(\Phi(\mathbf{t}_j) - \frac{1}{M} \sum_{n=1}^M \Phi(\mathbf{x}_n) \right) \\ &= \Phi(\mathbf{x}_i)^T \Phi(\mathbf{t}_j) - \frac{1}{M} \sum_{m=1}^M \Phi(\mathbf{x}_m)^T \Phi(\mathbf{t}_j) - \frac{1}{M} \sum_{n=1}^M \Phi(\mathbf{x}_i)^T \Phi(\mathbf{x}_n) + \frac{1}{M^2} \sum_{m,n=1}^M \Phi(\mathbf{x}_m)^T \Phi(\mathbf{x}_n) \\ &= \mathbf{K}_{ij}^{\text{test}} - \frac{1}{M} \sum_{m=1}^M \mathbf{I}_{im} \mathbf{K}_{mj}^{\text{test}} - \frac{1}{M} \sum_{n=1}^M \mathbf{K}_{in} \bar{\mathbf{I}}_{nj} + \frac{1}{M^2} \sum_{m,n=1}^M \mathbf{I}_{im} \mathbf{K}_{mn} \mathbf{I}_{nj} \end{aligned}$$

其中 $\mathbf{K}_{ij}^{\text{test}} = \Phi(\mathbf{x}_i)^T \Phi(\mathbf{t}_j)$ 。

转化为矩阵乘法，即

$$\bar{\mathbf{K}}^{\text{test}} = \mathbf{K}^{\text{test}} - \frac{1}{M} \mathbf{I}_M \mathbf{K}^{\text{test}} - \frac{1}{M} \mathbf{K} \mathbf{I}_{M \times L} + \frac{1}{M^2} \left(\sum_{m,n=1}^M \Phi(\mathbf{x}_m)^T \Phi(\mathbf{x}_n) \right) \mathbf{I}_{M \times L}$$

其中： $\mathbf{I}_M \in R^{M \times M}$ 和 $\mathbf{I}_{M \times L} \in R^{M \times L}$ 每一元素都为1。

这里还有一个小问题，由于 \mathbf{v} 受到单位向量的约束，所以 \mathbf{a} 也要受到约束，即

$$\begin{aligned} (\mathbf{v}, \mathbf{v}) &= \left(\sum_{i=1}^M a_i \Psi(\mathbf{x}_i) \right)^T \left(\sum_{j=1}^M a_j \Psi(\mathbf{x}_j) \right) \\ &= \sum_{i=1}^M \sum_{j=1}^M a_i a_j (\Psi(\mathbf{x}_i), \Psi(\mathbf{x}_j)) \\ &= \sum_{i=1}^M \sum_{j=1}^M a_i a_j \bar{\mathbf{K}}_{ij} \\ &= \bar{\lambda} \mathbf{a}^T \mathbf{a} \\ &= 1 \end{aligned}$$

其中 $\bar{\lambda}$ 为特征向量 \mathbf{a} 对应的 $\bar{\mathbf{K}}$ 的特征值。

这里令 $\mathbf{a}^T \mathbf{a}$ 也单位化为1，那么 $\mathbf{a}^T \mathbf{a}$ 除以 $\sqrt{\bar{\lambda}}$ 即能保证 $\|\mathbf{v}\|^2 = 1$ 。

3. KPCA算法步骤

- 1) 选择一个核函数
- 2) 计算核矩阵 \mathbf{K}
- 3) 按照 $\bar{\mathbf{K}} = \mathbf{K} - \mathbf{I}_M \mathbf{K} - \mathbf{K} \mathbf{I}_M - \mathbf{I}_M \mathbf{K} \mathbf{I}_M$ 计算中心化的核矩阵 $\bar{\mathbf{K}}$
- 4) 求出中心化核矩阵 $\bar{\mathbf{K}}$ 的特征向量和特征值
- 5) 将特征向量按对应特征值大小从上到下按行排列成矩阵，取前 k 列组成矩阵 α
- 6) 将每一行特征向量单位化，每一行特征向量除去对应特征值的开方值
- 7) 计算降维后数据的核主成分投影

$$y_j = \sum_{i=1}^M \alpha_{ji} K(x_i, x), j = 1, \dots, k \quad (3.1)$$

注意这里 y_j 是一个scalar，代表第 j 个核主成分， α_j 代表第 j 个特征向量， α_{ji} 代表第 j 个特征向量的第 i 个元素（ $i = 1, \dots, M$ ），每一个 i 对应了一个 $K(x_i, x)$ 。所以式（3.1）实际上是利用 α_{ji} 对每一个训练样本 x_i 和测试样本的核 $K(x_i, x)$ 加权求和。