

# 聚类基本问题之性能度量和距离计算

## 【参考资料】

周志华 《机器学习》

[一篇文章透彻解读聚类分析（附数据和R代码）](#)

先给出相关的符号定义。假定样本集  $D = \{x_1, x_2, \dots, x_m\}$  包含  $m$  个无标记样本，每个样本  $x_i = (x_{i1}; x_{i2}; \dots; x_{in})$  是一个  $n$  维特征向量，则聚类算法将样本集  $D$  划分为  $k$  个不相交的簇  $\{C_l | l = 1, 2, \dots, k\}$ ，其中  $C_{l'} \cap_{l' \neq l} C_l = \emptyset$  且  $D = \bigcup_{l=1}^k C_l$ 。相应地，我们用  $\lambda_j \in \{1, 2, \dots, k\}$  表示样本  $x_j$  的“簇标记”（cluster label），即  $x_j \in C_{\lambda_j}$ 。于是，聚类的结果可用包含  $m$  个元素的簇标记向量  $\lambda = (\lambda_1; \lambda_2; \dots; \lambda_m)$  表示。

聚类算法涉及到两个基本问题——性能度量和距离计算。

## 1. 性能度量

聚类的目标是“物以类聚”，即同一簇的样本尽可能彼此相似，不同簇的样本尽可能不同。换言之，聚类结果的“簇内相似度”（intra-cluster similarity）高且“簇间相似度”（inter-cluster similarity）低。

聚类性能度量大致有两类。一类是将聚类结果与某个“参考模型”进行比较，例如领域专家给出的划分结果，这类指标称为“外部指标”（external index）；另一类是直接考察聚类结果而不利用任何参考模型，称为“内部指标”（internal index）。

### 1.1 外部指标

假设数据集  $D = \{x_1, x_2, \dots, x_m\}$ ，经过聚类后得到的簇划分为  $C = \{C_1, C_2, \dots, C_s\}$ ，参考模型给出的簇划分  $C^* = \{C_1^*, C_2^*, \dots, C_s^*\}$ ，相应的，令  $\lambda$  和  $\lambda^*$  分别表示与  $C$  和  $C^*$  对应的簇标记向量。我们将样本两两配对考虑，定义：

$$\begin{aligned} a &= |SS|, SS = \{(x_i, x_j) | \lambda_i = \lambda_j, \lambda_i^* = \lambda_j^*, i < j\} \\ b &= |SD|, SD = \{(x_i, x_j) | \lambda_i = \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\} \\ c &= |DS|, DS = \{(x_i, x_j) | \lambda_i \neq \lambda_j, \lambda_i^* = \lambda_j^*, i < j\} \\ d &= |DD|, DD = \{(x_i, x_j) | \lambda_i \neq \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\} \end{aligned} \quad (1.1)$$

其中集合  $SS$  包含了在  $C$  中隶属于相同簇且在  $C^*$  中也隶属于相同簇的样本对，集合  $SD$  包含了在  $C$  中隶属于相同簇但在  $C^*$  中隶属于不同簇的样本对，其他以此类推。由于每个样本对  $(x_i, x_j)$  ( $i < j$ ) 仅能出现在一个集合中，因此有  $a + b + c + d = m(m-1)/2$  成立。

基于式 (1.1) 可以导出聚类性能度量常用的外部指标：

- Jaccard系数 (Jaccard Coefficient, JC)

$$JC = \frac{a}{a + b + c}$$

- FM指数 (Fowlkes and Mallows Index, FMI)

$$\text{FMI} = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$$

- Rand指数 (Rand Index, RI)

$$\text{RI} = \frac{2(a+d)}{m(m-1)}$$

显然，上述性能度量的结果均在 $[0, 1]$ 区间内，且值越大越好。

## 1.2 内部指标

考虑聚类结果的簇划分 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$ ，定义

$$\text{avg}(C) = \frac{2}{|C|(|C|-1)} \sum_{1 \leq i < j \leq |C|} \text{dist}(\mathbf{x}_i, \mathbf{x}_j) \quad (1.2)$$

$$\text{diam}(C) = \max_{1 \leq i < j \leq |C|} \text{dist}(\mathbf{x}_i, \mathbf{x}_j) \quad (1.3)$$

$$d_{\min}(C_i, C_j) = \min_{\mathbf{x}_i \in C_i, \mathbf{x}_j \in C_j} \text{dist}(\mathbf{x}_i, \mathbf{x}_j) \quad (1.4)$$

$$d_{\text{cen}}(C_i, C_j) = \text{dist}(\boldsymbol{\mu}_i, \boldsymbol{\mu}_j) \quad (1.5)$$

其中， $\text{dist}(\cdot, \cdot)$ 用于计算样本之间的距离； $\boldsymbol{\mu}$ 代表簇 $C$ 的中心点 $\boldsymbol{\mu} = \frac{1}{|C|} \sum_{1 \leq i \leq |C|} \mathbf{x}_i$ 。显然， $\text{avg}(C)$ 对应于簇 $C$ 内样本间的平均距离， $\text{diam}(C)$ 对应于簇 $C$ 内样本间的最远距离， $d_{\min}(C_i, C_j)$ 对应于簇 $C_i$ 与簇 $C_j$ 最近样本间的距离， $d_{\text{cen}}(C_i, C_j)$ 对应于簇 $C_i$ 与簇 $C_j$ 中心点间的距离。

基于式 (1.2) ~ (1.5) 可以导出常用的聚类性能度量指标：

- DB指数 (Davies-Bouldin Index, DBI)

$$\text{DBI} = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left( \frac{\text{avg}(C_i) + \text{avg}(C_j)}{d_{\text{cen}}(\boldsymbol{\mu}_i, \boldsymbol{\mu}_j)} \right)$$

- Dunn指数 (Dunn Index, DI)

$$\text{DI} = \min_{1 \leq i \leq k} \left\{ \min_{j \neq i} \left( \frac{d_{\min}(C_i, C_j)}{\max_{1 \leq l \leq k} \text{diam}(C_l)} \right) \right\}$$

显然，DBI的值越小越好，而DI则相反，值越大越好。

## 2. 距离计算

根据属性的数值类型不同，需要使用不同的距离计算方式，下面列举以下常见类型属性的距离计算方法。

### 2.1 数值属性

数值属性 (numerical attribute)，又称连续属性 (continuous attribute)，即取值连续的属性。给定样本 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{in})$ 与样本 $\mathbf{x}_j = (x_{j1}; x_{j2}; \dots; x_{jn})$ ，最常用的是闵科夫斯基距离 (Minkowski Distance)：

$$\text{dist}_{\text{mk}}(\mathbf{x}_i, \mathbf{x}_j) = \left( \sum_{u=1}^n |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}$$

$p = 2$ 时，闵科夫斯基距离即**欧式距离**（Euclidean Distance）：

$$\text{dist}_{\text{ed}}(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{u=1}^n |x_{iu} - x_{ju}|^2}$$

$p = 1$ 时，闵科夫斯基距离即**曼哈顿距离**（Manhattan Distance）：

$$\text{dist}_{\text{man}}(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_1 = \sum_{u=1}^n |x_{iu} - x_{ju}|$$

当样本空间中不同属性的重要性不同时，可使用“加权距离”，如带权闵科夫斯基距离：

$$\text{dist}_{\text{wmk}}(\mathbf{x}_i, \mathbf{x}_j) = (w_1 \cdot |x_{i1} - x_{j1}|^p + \dots + w_n \cdot |x_{in} - x_{jn}|^p)^{\frac{1}{p}}$$

需要注意的是，在计算连续属性之间的距离时，需要考虑数据标度的问题，比如某个属性取值范围是（2000，3000），另一个属性的取值范围是（10，20）。这时需要对数据进行标准化，比如Z-score标准化：

$$Z_f = \frac{X_f - \text{mean}_f}{S_f}$$

## 2.2 二值属性

即取值为0或1的属性，可以利用**列联表**（contingency table）和**Jaccard相似度**计算距离。我们通过一个例子来说明二值属性的距离计算。

假设我们有三个同学，他们有不同的特征，我们想衡量他们哪一对特征更接近的：

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M	Yes	No	Pos	Neg	Neg	Neg
Mary	F	Yes	No	Pos	Neg	Pos	Neg
Jim	M	Yes	Yes	Neg	Neg	Neg	Pos

我们首先将变量用0，1表示

Name	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	1	0	1	0	0	0
Mary	1	0	1	0	1	0
Jim	1	1	0	0	0	1

对于样本X和Y，建立如下的列联表

		Y		
		1	0	sum
X	1	a	b	a+b
	0	c	d	c+d
	sum	a+c	b+d	p

其中 $a$ 代表的是 $X$ 和 $Y$ 中取值都为1的属性数，其他以此类推。我们使用Jaccard相似度来计算距离，如下：

$$d(X, Y) = \frac{b + c}{a + b + c}$$

Jaccard相似度实际上就是交并比，这里改变了它的原始定义（原来分母上应为 $a$ ），因为需要遵循“距离越大相似度越小”的原则。 $b + c$ 代表的是样本 $X$ 和样本 $Y$ 中，其中一方取1，另一方取0的情况。

于是，我们可以计算这三位同学的距离：

$$d(Jack, Mary) = \frac{0 + 1}{2 + 0 + 1} = 0.33$$

$$d(Jack, Jim) = \frac{1 + 2}{1 + 1 + 2} = 0.75$$

$$d(Mary, Jim) = \frac{2 + 2}{1 + 2 + 2} = 0.8$$

所以Jack和Mary是最相近的两个。

### 2.3 有序属性

有序属性（ordinal attribute）的取值通常是离散的，但是不同的取值间有顺序关系，比如 $Level \in \{Low, Medium, High\}$ 。计算距离的方法是转化为连续变量，再用闵科夫斯基距离计算，即：

- 1) 用每个值对应的排名 $r \in [1 \dots N]$ 来代替这个值；
- 2) 计算z-scores来标准化排名，让 $r$ 在 $[0, 1]$ 之间；
- 3) 计算闵科夫斯基距离。


ID	Level	...			
1	Medium	...	Ranks		
2	Low	...			
3	High	...			
4	Medium	...			
...	...	...			
ID	Level	...			
1	2	...	Z-scores		
2	1	...			
3	3	...			
4	2	...			
...	...	...			
ID	Level	...			
1	0.5	...			
2	0.0	...			
3	1.0	...			
4	0.5	...			
...	...	...			

### 2.4 无序属性

无序属性，或者说类别属性，取值是离散的，例如 $Color \in \{blue, green, red, \dots\}$ 。这里介绍两种处理方法。

第一种是将类别属性二值化，比如

ID	Color	...
1	Blue	...
2	Green	...
3	Red	...
...	...	...

Binarization 

ID	Blue	Green	Red	...
1	1	0	0	...
2	0	1	0	...
3	0	0	1	...
...	...	...	...	...

转化成二值属性之后再列联表分析。

第二种是采用**VDM** (Value Difference Metric) 。令 $m_{u,a}$ 表示在属性 $u$ 上取值为 $a$ 的样本数， $m_{u,a,i}$ 表示在第 $i$ 个样本簇中在属性 $u$ 上取值为 $a$ 的样本数， $k$ 为样本簇数，则属性 $u$ 上两个离散值 $a$ 与 $b$ 之间的VDM距离为

$$\text{VDM}_p(a, b) = \sum_{i=1}^k \left| \frac{m_{u,a,i}}{m_{u,a}} - \frac{m_{u,b,i}}{m_{u,b}} \right|^p$$

使用VDM的另一个好处是，可以结合闵科夫斯基距离处理混合属性。假定有 $n_c$ 个有序属性、 $n - n_c$ 个无序属性，不失一般性，令有序属性排列在无序属性之前，则

$$\text{MinkovDM}_p(\mathbf{x}_i, \mathbf{x}_j) = \left( \sum_{u=1}^{n_c} |x_{iu} - x_{ju}|^p + \sum_{u=n_c+1}^n \text{VDM}_p(x_{iu}, x_{ju}) \right)^{\frac{1}{p}}$$