

EM算法与混合高斯模型

【参考资料】

吴恩达 CS229

周志华 《机器学习》

[详解EM算法与混合高斯模型\(Gaussian mixture model, GMM\)](#)

1. 混合高斯模型

首先回顾一下一维高斯分布的概率密度函数：

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

其中 μ 和 σ^2 分别为均值和方差。

多维变量 $X = (x_1, x_2, \dots, x_n)$ 的联合概率密度函数为：

$$f(X) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(X-u)^T \Sigma^{-1}(X-u)\right]$$

其中， n 为变量维数， $u = (u_1, u_2, \dots, u_n)$ 为均值， Σ 为协方差矩阵。

混合高斯模型（Gaussian mixture model, GMM）就是多个高斯分布的合成。假设组成GMM的高斯分布有 K 个，则GMM的概率密度函数如下：


$$p(x) = \sum_{j=1}^K p(j)p(x|j) = \sum_{j=1}^K \phi_j N(x|u_j, \Sigma_j)$$

其中 $p(x|j) = N(x|u_j, \Sigma_j)$ 是第 j 个高斯分布的概率密度函数，可以看成是选定第 j 个高斯分布后，该高斯分布产生 x 的概率； $p(j) = \phi_j$ 是第 j 个高斯分布的权重，也可以视为选择第 j 个高斯分布的概率，并且满足 $\sum_{j=1}^K \phi_j = 1$ 。

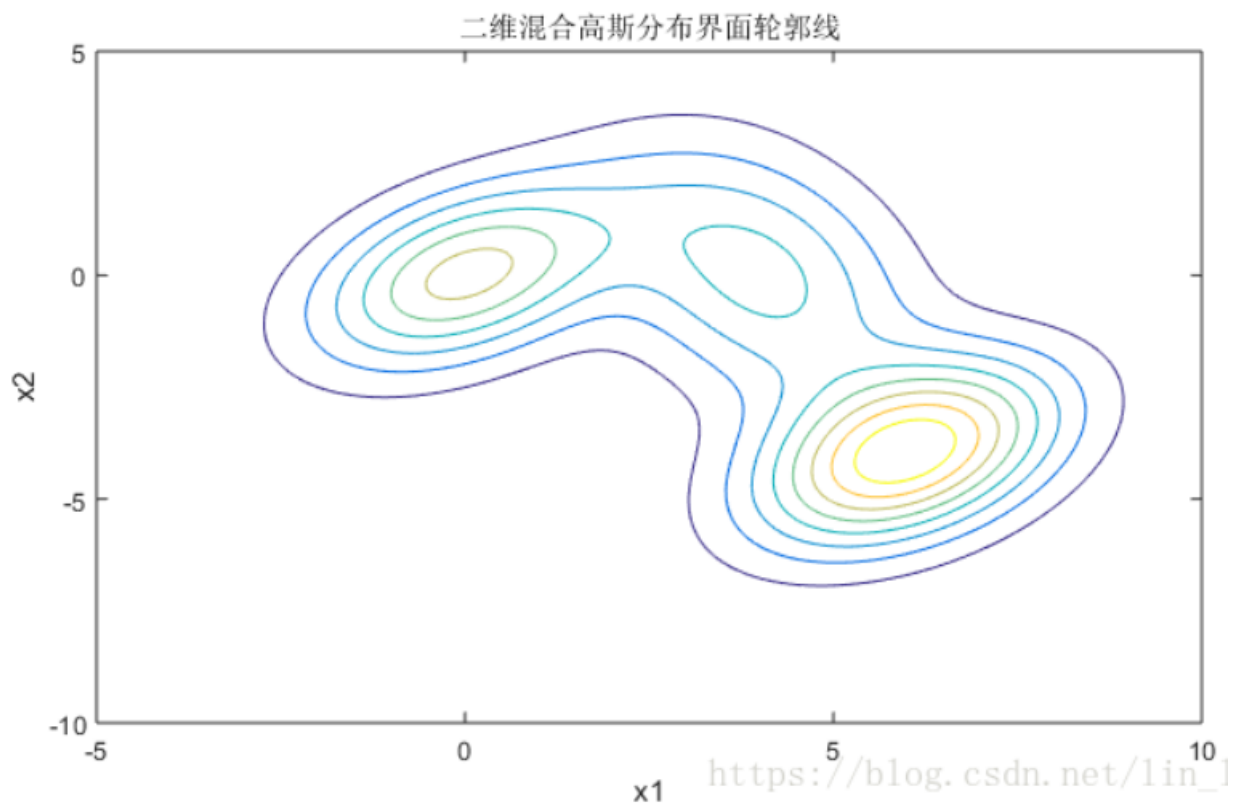
所以，混合高斯模型并不是什么新奇的东西，它的本质就是融合几个单高斯模型，来使得模型更加复杂，从而产生更复杂的样本。理论上，如果某个混合高斯模型融合的高斯模型个数足够多，它们之间的权重设定得足够合理，这个混合模型可以拟合任意分布的样本。

GMM的图例如下

一维的情形：



二维空间中三个高斯分布的混合：



2. EM算法估计参数

GMM的参数有各个高斯成分对应的均值 μ 与协方差 Σ ，以及它们的权重 ϕ 。在估计GMM模型参数时的一个问题是，我们无法确定观测到的样本 x 具体是由哪一个高斯成分产生的。换句话说，“哪一个高斯分布”是一个隐变量，我们把它用 z 来表示。这时候，就需要用到EM算法来估计GMM的参数。

对于特定的样本 i ，我们假设 z 服从一个参数为 ϕ 的多项式分布，并且 $\phi_j \geq 0$ ， $\sum_{j=1}^k \phi_j = 1$ ，其中 j 表示单个高斯成分的序号。于是有：

$$p(z^{(i)} = j) = \phi_j$$

表示选择第 j 个高斯分布的概率是 ϕ_j ，并且我们有：

$$x^{(i)} | z^{(i)} = j \sim \mathcal{N}(\mu_j, \Sigma_j)$$

即 $x^{(i)}$ 是由这第 j 个高斯分布产生的。所以，总的似然函数为：

$$\begin{aligned} \ell(\phi, \mu, \Sigma) &= \sum_{i=1}^m \log p(x^{(i)}; \phi, \mu, \Sigma) \\ &= \sum_{i=1}^m \log \sum_{z^{(i)}=1}^k p(x^{(i)} | z^{(i)}; \mu, \Sigma) p(z^{(i)}; \phi) \end{aligned}$$

所以，我们需要估计的参数是 ϕ_j ， μ_j ， Σ_j 。接下来就是调用EM算法的步骤，首先初始化一组 ϕ_j ， μ_j ， Σ_j 。然后在**E-Step**中，我们利用贝叶斯公式，计算 $z^{(i)}$ 的后验概率：

$$\begin{aligned} w_j^{(i)} &= Q_i(z^{(i)} = j) = P(z^{(i)} = j | x^{(i)}; \phi, \mu, \Sigma) \\ &= \frac{p(x^{(i)} | z^{(i)} = j; \mu, \Sigma) p(z^{(i)} = j; \phi)}{\sum_{l=1}^k p(x^{(i)} | z^{(i)} = l; \mu, \Sigma) p(z^{(i)} = l; \phi)} \end{aligned}$$

$w_j^{(i)}$ 就代表我们对 $z^{(i)}$ 的选择的一种“猜测”，并且因为计算的是概率，所以这是一种“soft”的、不确定的猜测。

接下来，利用我们对 $z^{(i)}$ 的猜测，在**M-Step**中更新参数，也就是说，我们要最大化下面的似然函数：

$$\begin{aligned} &\sum_{i=1}^m \sum_z Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \phi, \mu, \Sigma)}{Q_i(z^{(i)})} \\ &= \sum_{i=1}^m \sum_{j=1}^k Q_i(z^{(i)} = j) \log \frac{p(x^{(i)} | z^{(i)} = j; \mu, \Sigma) p(z^{(i)} = j; \phi)}{Q_i(z^{(i)} = j)} \\ &= \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \log \frac{\frac{1}{(2\pi)^{n/2} |\Sigma_j|^{1/2}} \exp\left(-\frac{1}{2} (x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j)\right) \cdot \phi_j}{w_j^{(i)}} \end{aligned}$$

为了更新参数 μ_j ，我们把上面的似然函数对 μ_j 求导：

$$\begin{aligned}
& \nabla_{\mu_j} \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \log \frac{\frac{1}{(2\pi)^{n/2} |\Sigma_j|^{1/2}} \exp\left(-\frac{1}{2} (x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j)\right) \cdot \phi_j}{w_j^{(i)}} \\
&= -\nabla_{\mu_j} \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \frac{1}{2} (x^{(i)} - \mu_j)^T \Sigma_j^{-1} (x^{(i)} - \mu_j) \\
&= \sum_{i=1}^m w_j^{(i)} (\Sigma_j^{-1} x^{(i)} - \Sigma_j^{-1} \mu_j)
\end{aligned}$$

令其等于0, 可得

$$\mu_j := \frac{\sum_{i=1}^m w_j^{(i)} x^{(i)}}{\sum_{i=1}^m w_j^{(i)}}$$

即各混合成分的均值可通过样本加权平均来估计, 样本权重是属于该成分的后验概率。

接下来推导 ϕ_j 的更新规则, 在似然函数中, 与 ϕ_j 有关的项为

$$\sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \log \phi_j$$

但是, 由于 ϕ_j 是一个概率, 所以它还需要满足 $\sum_{j=1}^k \phi_j = 1$ 的约束条件, 因此构造拉格朗日算子为

$$\mathcal{L}(\phi) = \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} \log \phi_j + \beta \left(\sum_{j=1}^k \phi_j - 1 \right)$$

其中 β 是拉格朗日乘子。对上式求导, 可得

$$\frac{\partial}{\partial \phi_j} \mathcal{L}(\phi) = \sum_{i=1}^m \frac{w_j^{(i)}}{\phi_j} + \beta$$

将其置零, 可得

$$\phi_j = \frac{\sum_{i=1}^m w_j^{(i)}}{-\beta}$$

利用约束 $\sum_j \phi_j = 1$, 我们可以将上式改写为:

$$-\beta = \sum_{i=1}^m \sum_{j=1}^k w_j^{(i)} = \sum_{i=1}^m 1 = m$$

这里利用了 $\sum_j w_j^{(i)} = 1$ 。

于是 ϕ_j 的更新就可以表示为

$$\phi_j := \frac{1}{m} \sum_{i=1}^m w_j^{(i)}$$

即每个高斯成分的混合系数由样本属于该成分的平均后验概率确定。

同理，可以得到 Σ_j 的更新规则。

各个参数的更新规则总结如下：

$$\begin{aligned}\phi_j &:= \frac{1}{m} \sum_{i=1}^m w_j^{(i)} \\ \mu_j &:= \frac{\sum_{i=1}^m w_j^{(i)} x^{(i)}}{\sum_{i=1}^m w_j^{(i)}} \\ \Sigma_j &:= \frac{\sum_{i=1}^m w_j^{(i)} (x^{(i)} - \mu_j) (x^{(i)} - \mu_j)^T}{\sum_{i=1}^m w_j^{(i)}}\end{aligned}$$